

自适应多工况过程监测：基于模式匹配与相似性保持字典学习

论文信息

- 论文标题**: Adaptive Multimode Process Monitoring Based on Mode-Matching and Similarity-Preserving Dictionary Learning
- 作者团队**: Keke Huang, Zui Tao, Yishun Liu, Bei Sun, Chunhua Yang (IEEE Fellow), Weihua Gui, Shiyang Hu (IEEE Senior Member)
- 发表信息**: IEEE Transactions on Instrumentation and Measurement, 2026
- 关键词**: Adaptive model updating, Dictionary learning, Model mismatch, Multimode process modeling, Process monitoring

Abstract 摘要解读

在实际工业过程中，制造策略和生产工艺的变化会导致新工况的不断出现。虽然工业 SCADA 系统积累了大量历史数据可用于多工况建模与监测，但基于历史数据训练的模型难以适应新兴工况，导致模型失配（model mismatch）。另一方面，用新工况数据更新模型虽然能使模型匹配新工况，但可能导致模型丧失对历史工况的表征能力，即“灾难性遗忘”（catastrophic forgetting）。

针对上述问题，本文提出了联合模式匹配与相似性保持字典学习（JMSDL）方法。该方法通过学习新工况数据来更新模型，使其能够自适应匹配新出现的工况；同时引入相似性度量，保证更新后的方法对历史数据仍具有表征能力。数值仿真实验、CSTH 过程实验和工业焙烧过程实验均表明，JMSDL 方法能够在匹配新工况的同时保持对历史工况的监测性能，在故障检测率和误报率方面显著优于现有方法。

Introduction 引言分析

研究背景与动机

工业过程日益复杂，小故障可能引发严重事故。过程监测通过实时获取工业过程状态，在故障发生时及时报警，对保障生产安全具有重要意义。

现有方法的分类与局限

数据驱动的过程监测方法可分为三大类：

方法类别	核心思想	局限性
------	------	-----

多模型方法	用多个模型分别匹配每个工况	模型数量持续增长，空间复杂度高； 在线匹配耗时
全局建模方法	用单一模型同时表征所有工况	统计平均效应导致对各工况表征不精确； 新工况出现时需完全重训
在线模型更新方法	用新工况数据在线更新模型	面临“灾难性遗忘”问题，更新后丢失 对历史工况的表征能力

本文创新点

- 提出 JMSDL 方法，通过最小化新工况数据的重构误差实现模型自适应匹配
- 在优化函数中引入保持项（preservation term），保证更新前后模型的相似性，克服灾难性遗忘
- 建立面向多工况过程监测的持续学习框架，实现对新工况的自适应

Methodology 方法详解

整体框架

JMSDL 方法的框架如 Figure 3 所示，包含两个核心部分：重构项（学习新知识）和保持项（保持旧知识）。整体流程为：首先用 K-SVD 方法对第一个工况训练初始字典；当新工况出现时，仅用新工况数据通过 JMSDL 方法更新字典，使更新后的字典既能表征新工况，又不丢失对历史工况的表征能力。

初始建模

字典学习的目标是学习一个过完备字典 D ，用少量原子线性重构数据。初始建模的优化问题为：

公式 (1) 定义了带稀疏约束的字典学习目标：

其中 X 是第一个工况的训练数据， D 是字典矩阵， W 是稀疏编码矩阵， $\|\cdot\|_F$ 是 Frobenius 范数， T 是稀疏度。最小化重构误差确保字典对数据有足够的表征能力， L 范数约束确保每个样本最多用 T 个原子重构。

实际求解中，常用 L_1 范数近似替代 L_0 范数，将约束优化转化为无约束优化：

公式 (2) 的含义：在重构误差和稀疏度之间取得平衡， λ 控制稀疏惩罚强度。采用交替迭代法求解：固定 W 用 K-SVD 更新 D ，固定 D 用 OMP 更新 W 。

自适应模型更新（JMSDL 核心）

定义更新前的旧字典为 D_o ，更新后的新字典为 D_n 。JMSDL 的目标分为两部分：

模式匹配 (Mode-Matching)：使新字典能表征新工况数据，即最小化重构项 $\|X_n - D_n W\|_F^2$ 。

相似性保持 (Similarity-Preserving)：保持 D_n 与 D_o 足够相似，确保对历史数据的表征能力。

公式 (3) 定义了相似性矩阵 $D_o^T D_n$ ：

该矩阵的对角元素是两个字典相同位置原子的内积。由于原子均为单位向量，当两个原子非常相似时，其内积趋近于 1。通过对角单位化操作，强制相似性矩阵的对角元素趋近于 1，从而保持 D_o 与 D_n 的相似性。

公式 (4) 给出了 JMSDL 的完整优化问题：

- 第一项：重构项，确保新字典能表征新工况数据
- 第二项：保持项 $\text{tr}(I - D_o^T D_n)$ ，确保新旧字典相似
- 第三项：稀疏惩罚项 $\lambda \|W\|$

优化算法

采用交替优化策略：

Step 1: 更新 D_n (固定 W)。通过求导得到闭式解：

对 $B = WW^T$ 进行正交对角分解 $B = MVM^T$ ，最终得到 $D_n = QM^T$ ，其中 $Q(i, j) = P(i, j)/V(j, j)$ ， $P = FM$ ， $F = X_n W^T + (1/2) \lambda D_o$ 。

Step 2: 更新 W (固定 D_n)。使用 OMP 方法直接求解稀疏编码。

两步交替迭代直至收敛。虽然 (4) 对 (D_n, W) 非联合凸，但固定其中一个变量时对另一个是凸的，因此优化算法的收敛性可以保证。

在线监测

训练完成后，使用最终字典 D_c 进行在线监测：

1. **计算控制限****：用 D_c 重构所有训练样本，计算重构误差 $R_i = \|x_i - D_c w_i\|^2$ ，再用核密度估计 (KDE) 方法在给定置信水平 α 下确定控制限 R_{tr} 。
2. **在线数据监测****：对在线数据 x_{new} ，用 OMP 求解稀疏编码 w_{new} ，计算重构误差 $IRE_{new} = \|x_{new} - D_c w_{new}\|^2$ 。若 $IRE_{new} > R_{tr}$ ，判定为故障；否则为正常。

Experiments 实验分析

实验设置

评价指标：

- 字典相似度 $ds = (1/K) \sum |d_{o_i}^T d_{n_i}|$ ，越接近 1 表示两个字典越相似
- 平均重构误差 $MRE = (1/m) \sum IRE_i$ ，越小表示表征能力越强
- 故障检测率 $FDR = tp/\text{总故障样本数} \times 100\%$
- 误报率 $FAR = fp/\text{总正常样本数} \times 100\%$

对比方法：

方法	类型	核心思想	与 JMSDL 的区别
mPCA [29]	全局建模	PCA 混合模型	统计平均效应导致部分工况表征不佳
DL [14]	单工况建模	传统字典学习 (K-SVD)	无法处理多工况数据，面临灾难性遗忘
LCDL [30]	全局建模	标签一致字典学习	用单一字典表征所有工况，控制限过高
ODL [32]	在线更新	在线字典学习	缺乏保持项，存在灾难性遗忘问题

实验一：数值仿真

设计多工况数据生成系统 $x = A_i s + e$ ，使用 4 个不同的随机观测矩阵 A_i 生成 4 个工况的数据，每个工况 1000 个训练样本、250 个测试样本。

敏感性分析： λ 增大时，字典相似度 ds 增大，标准差减小，验证了优化算法的可行性。

数据表征实验： D 仅能表征工况 1， D 能表征工况 1 和 2， D 能表征工况 1-3， D 能表征全部 4 个工况。每次更新后，对已学习工况的 MRE 保持在较低水平，验证了 JMSDL 能持续学习新工况且不发生灾难性遗忘。

过程监测实验：在每个工况的最后 125 个样本中加入偏差故障。JMSDL 方法对各工况正常数据的重构误差小，对故障数据的重构误差大，能有效区分正常与故障数据。

实验二：CSTH 仿真过程

CSTH 过程是广泛使用的工业基准过程，设置 3 个工况（不同液位、温度、热水阀参数），每个工况 1000 个训练样本、250 个测试样本。

数据表征结果 (Table II)：

字典	MRE (工况 1)	MRE (工况 2)	MRE (工况 3)
D	0.00047	3.2891	4.7353
D	0.00096	0.0014	15.4292
D	0.0013	0.0044	0.0021

每次更新后，对已学习工况的 MRE 显著降低并保持在同一水平。

过程监测实验：在三个工况上分别设置偏差故障和乘法故障。mPCA 仅能检测温度上的乘法故障；DL 无法检测液位偏差故障；LCDL 无法检测流量乘法故障；ODL 在新工况出现时存在灾难性遗忘。JMSDL 方法在所有工况上均表现出最优的监测效果。

实验三：工业焙烧过程

对湖南某锌冶炼厂的焙烧过程进行实验验证。采集 25 维变量数据（温度、流量、压力等），选取 4 种工况：高效工况（模式 1）、高效过分解工况（模式 2）、高效欠氧化工况（模式 3）、健康工况（模式 4），每种工况 1000 个训练样本、500 个测试样本。

实验结果：JMSDL 方法在实际工业过程中同样能持续学习新工况且不发生灾难性遗忘，各工况的重构误差保持在同一水平。在故障监测方面，JMSDL 方法显著优于所有对比方法。

Conclusion 结论与展望

核心贡献总结

本文针对多工况工业过程的建模与监测问题，提出了 JMSDL 自适应多工况过程建模与监测方法。核心贡献在于：通过重构项实现对新工况的自适应匹配，通过保持项克服灾难性遗忘问题，建立了面向多工况过程监测的持续学习框架。

已知局限性

- JMSDL 方法是一种有监督方法，需要工况标签
- 当前对所有原子施加相同的相似性约束，未考虑不同原子之间的差异性

未来研究方向

- 进行更细粒度的处理，如考虑每个原子之间不同程度的相似性
- 探索无监督或半监督的工况识别方法

创新点总结

#	创新点	具体内容	解决的问题
1	JMSDL 自适应更新方法	通过最小化新工况数据的重构误差实现模型匹配	传统模型难以适应不断出现的新工况

2	相似性保持机制	在优化函数中引入保持项 $\text{tr}(\mathbf{I} - \mathbf{D}_o \hat{\mathbf{T}} \mathbf{D}_n)$ ，强制更新前后字典的对角相似性趋近于 1	在线更新方法面临的灾难性遗忘问题
3	持续学习框架	初始字典用 K-SVD 训练，后续工况依次用 JMSDL 增量更新	多模型方法模型数量膨胀、全局建模方法统计平均效应

实验设计总结

数据集

数据集	工况数	样本维度	训练样本	测试样本	特点
数值仿真	4	20	4000	1000	随机观测矩阵生成不同工况
CSTH 过程	3	多维	3000	750+750	工业基准过程，含液位/温度/流量故障
焙烧过程	4	25	4000	2000+500	真实工业数据，锌冶炼焙烧过程

关键结果（焙烧过程）

方法	能否检测所有工况故障	灾难性遗忘	FAR	FDR
mPCA	部分工况	不适用	较高	较低
DL	部分工况	严重	高	低
LCDL	部分工况	无	低	低
ODL	能检测	严重	高	中
JMSDL	**全部工况**	**无**	**低**	**高**